


DEEP LEARNING · CARDIOLOGIE

Prédiction de maladie cardiaque par Deep Learning

Dataset : Heart Disease (UCI / Heart.csv) · 918 patients · Classification binaire

Encadrant : **M. Abdallah Khemais**



Made with GAMMA

Prédire la maladie cardiaque à partir de données cliniques



Objectif

Classification binaire : **HeartDisease = 0** (sain) ou **1** (malade), à partir de 11 caractéristiques cliniques.

Dataset — 918 patients

- **Features continues** : Age, RestingBP, Cholesterol, MaxHR, Oldpeak
- **Features catégorielles** : ChestPainType, RestingECG, ST_Slope, Sex
- **Binaire** : FastingBS, ExerciseAngina

i Distribution des classes : ~55 % malades / 45 % sains — dataset équilibré.

Exploration et préparation des données

01

Gestion des valeurs aberrantes

Suppression ou imputation des valeurs invalides (RestingBP = 0, Cholesterol = 0).

03

Normalisation

StandardScaler sur les features continues : Age, RestingBP, Cholesterol, MaxHR, Oldpeak.

02

Encodage des variables catégorielles


One-Hot Encoding : ChestPainType, RestingECG, ST_Slope, Sex.

04

Segmentation des données

Split train / validation / test (60 / 20 / 20) ou cross-validation stratifiée.

Réseau de neurones dense — Multi-Layer Perceptron



Le MLP est adapté aux données tabulaires. CNN et RNN conviennent aux images et séquences temporelles — non pertinents ici.

Optimiseur : **Adam** (lr = 0.001) · Perte : **Binary Cross-Entropy**.

Gestion du surapprentissage



Early Stopping

patience = 10, restore_best_weights — arrêt automatique si la loss validation stagne.



Dropout 0.3

Désactivation aléatoire de 30 % des neurones à chaque couche dense — évite la co-adaptation.



ReduceLROnPlateau

Réduction automatique du learning rate lorsque la performance se stabilise.




Batch Normalization

Normalisation des activations — accélère la convergence et régularise le modèle (optionnel).

Comparaison des architectures

■ Accuracy validation (%)

■ AUC-ROC (%)




Modèle retenu

Le **MLP profond** (128 → 64 → 32, dropout 0.3) obtient les meilleures performances : **86 % d'accuracy** et **AUC = 0.91** sur la validation.

L'ajout de Batch Normalization n'améliore pas significativement les résultats. La simplicité et la robustesse du MLP profond en font le choix optimal.

✓ Meilleur compromis performance / complexité —
retenu pour l'évaluation finale.

Courbes d'apprentissage et métriques de performance




Interprétation

Les courbes de loss convergent sans écart significatif — **aucun surapprentissage majeur**. Plateau atteint vers l'époque 45 → early stopping activé.

- **AUC $\approx$ 0.91** — excellent pouvoir discriminant
- **Sensibilité (Recall) = 78 %**
- **Spécificité = 82 %**

Matrice de confusion et résultats finaux



Métriques finales — ensemble de test

Le modèle identifie correctement **78 patients malades sur 100** et **82 patients sains sur 100**.

85 %

Accuracy

0.84

F1-Score

0.91

AUC-ROC

CONCLUSION

Conclusion & perspectives d'amélioration

Résultats obtenus


Accuracy 85 %, F1-Score 0.84, AUC 0.91 — performances solides pour un MLP sur données tabulaires cliniques.

Limites identifiées


Données tabulaires simples ; suppression de valeurs aberrantes (Cholesterol = 0) entraînant une perte d'informations.

Améliorations envisagées

Baseline XGBoost / Random Forest · Feature engineering (catégories d'âge, interactions) · Déploiement Streamlit avec interface de prédiction interactive.



Déploiement Streamlit & structure du dépôt



Application interactive

L'utilisateur saisit ses paramètres cliniques et obtient instantanément une prédiction avec probabilité.

- Champs de saisie pour chaque feature
- Affichage : Risque élevé / faible + probabilité
- Hébergement : Streamlit Cloud ou Hugging Face Spaces

Structure du dépôt GitHub

- `notebooks/final_model.ipynb` — pipeline complet
- `app.py` — application Streamlit
- `README.md` + `requirements.txt`